



Università di Pisa

Scuola di Ingegneria

Dipartimento di Ingegneria dell'Informazione

Corso di Laurea in
Ingegneria Informatica

**Intelligenza artificiale per il riconoscimento di
emozioni tramite dati provenienti da una rete di
sensori wearable**

Relatori

Beatrice Lazzerini

Francesco Pistolesi

Candidato

Franco Terranova

ANNO ACCADEMICO 2020/2021

INTRODUZIONE

Le emozioni sono fondamentali per la vita umana, pilotano i nostri pensieri, condizionano le nostre giornate e il nostro processo decisionale.

Il fenomeno di interazione tra le emozioni degli individui forma una rete complessa e il mistero che circonda le emozioni, il loro funzionamento e come possano influenzare le nostre vite, non è stato ancora svelato.

I segnali fisiologici di un individuo, quali la frequenza cardiaca, la risposta galvanica della pelle, l'attività elettrica dei muscoli e i segnali elettrici del cervello sono fortemente legati al suo stato emotivo.

Questi, quindi, sono degli indicatori fondamentali per il riconoscimento delle emozioni e, grazie allo sviluppo della tecnologia, possono essere facilmente misurabili attraverso dispositivi indossabili non invasivi.

L'obiettivo del presente elaborato è quello di utilizzare l'intelligenza artificiale per permettere il riconoscimento di emozioni tramite dati provenienti da una rete di sensori wearable.

Il riconoscimento delle emozioni ha ottenuto un notevole interesse negli ultimi anni, sia in ambito accademico che industriale, grazie alle tecniche di machine learning e il loro contributo all'analisi e all'identificazione della relazione tra emozioni e segnali fisiologici.

Il presente studio è stato condotto attraverso le seguenti fasi: 1) una prima fase di raccolta dati, utilizzando la rete di sensori biometrici per il monitoraggio delle emozioni del tesista e di quelle di altri soggetti coinvolti; 2) una seconda fase di elaborazione dei dati raccolti; 3) una terza ed ultima fase, in cui si è messa in atto una valutazione dei risultati ottenuti.

INDICE

INTRODUZIONE	2
1. EMOZIONI	6
1.1. LE EMOZIONI AI TEMPI DEL COVID-19	7
1.2. INTERAZIONE UOMO-COMPUTER (HCI)	8
1.3. AFFECTIVE COMPUTING.....	8
1.4. MODELLI DI CLASSIFICAZIONE DELLE EMOZIONI	9
1.5. DAI SEGNALI FISIOLOGICI AGLI STATI EMOTIVI	11
1.5.1. FOTOPLETISMOGRAFIA (PPG)	11
1.5.2. ELETTROENCEFALOGRAFIA (EEG)	13
1.5.3. RISPOSTA GALVANICA DELLA PELLE (GSR).....	15
1.5.1. ELETTROMIOGRAFIA (EMG)	16
2. TECNICHE DI MACHINE LEARNING PER LA CLASSIFICAZIONE DI DATI	17
2.1. K-NEAREST NEIGHBORS (KNN).....	18
2.2. SUPPORT VECTOR MACHINES (SVM)	18
2.3. DECISION TREES (DT)	19
2.4. BAYESIAN NETWORKS (BN)	20
2.5. ENSEMBLE LEARNING	21
2.6. ARTIFICIAL NEURAL NETWORKS (ANN)	22
2.6.1. BACKPROPAGATION.....	24
3. RACCOLTA DEI DATI	26
3.1. SHIMMER3 GSR+ UNIT	26
3.2. SHIMMER3 EMG UNIT	27
3.3. MUSE S.....	29

3.4. SMART EMOTIONS.....	29
4. ELABORAZIONE DEI DATI.....	31
4.1. MATLAB E SIGNAL PROCESSING TOOLBOX	31
4.2. DATA PREPROCESSING	32
4.3. ESTRAZIONE DELLE FEATURE.....	32
4.4. FEATURE SELECTION	35
5. RISULTATI SPERIMENTALI	37
5.1. K-FOLD CROSS VALIDATION.....	37
5.2. VALUTAZIONE MODELLI.....	38
CONCLUSIONI.....	40
RINGRAZIAMENTI	41
INDICE DELLE FIGURE	42
INDICE DEI GRAFICI.....	43
BIBLIOGRAFIA.....	44

*“Tutti sanno cos’è un’emozione,
finché non gli viene chiesto di darne una definizione.”*

(Fehr e Russel, 1984)

1. EMOZIONI

Anche se non si è ancora giunti ad una definizione condivisa di emozione, senza dubbio tutti concordano sul fatto che quest’ultime giocano un ruolo molto importante nella nostra vita quotidiana, riuscendo a incidere direttamente sulla nostra attenzione, sulle nostre abilità di decisione e sulla nostra memoria.

Sono presenti qualunque cosa facciamo, ovunque noi siamo, senza esserne consapevoli per buona parte del tempo.

Una possibile definizione di emozione è quella di risposta dell’organismo a stimoli, immaginari o reali, che si manifestano con modificazioni corporee misurabili, quali la temperatura corporea o la frequenza del battito cardiaco.

Già nelle teorie classiche, la maggior parte dei tentativi di definire un’emozione risultavano astratti, mentre in ambito scientifico le emozioni venivano viste come non pertinenti ad esso.

I principi scientifici derivano infatti da ragionamenti logici, ipotesi testabili ed esperimenti replicabili.

Il punto di partenza dello studio delle emozioni in ambito scientifico si ebbe nel 1872 con Charles Darwin, grazie all’opera “L’espressione delle emozioni nell’uomo e negli animali”, nella quale le emozioni venivano descritte come regolate da programmi neurali prefissati geneticamente.

Da allora un susseguirsi di ricerche iniziarono a essere svolte in tutto il mondo.

Lo psicologo Paul Ekman approfondì le osservazioni di Darwin, scoprendo come le espressioni delle varie emozioni, anche tra individui appartenenti a culture diverse, siano identiche.

Le emozioni sono modi di reagire scritti nel codice comune dell’umanità.

1.1. LE EMOZIONI AI TEMPI DEL COVID-19

La pandemia da Covid-19 è un esempio molto pratico e attuale sull'importanza delle emozioni.

Sin dall'arrivo del Covid-19 e delle restrizioni adottate per evitarne la diffusione, si è sentito parlare di un aumento del disagio emotivo e di un susseguirsi di forme di depressione e di ansia.

Siamo vittime di un continuo succedersi di paure, incertezze, cambiamenti della routine e tutto ciò sollecita il nostro cervello emotivo, che deve essere in grado di reagire cercando di trovare un punto di equilibrio.

In seguito all'introduzione delle regole di distanziamento fisico, il tempo speso sui social network ha subito un fortissimo aumento e quest'ultimi sono diventati un ottimo territorio di ricerca per il monitoraggio del benessere pubblico, con risultati che confermano il continuo aumento di emozioni negative.

Uno studio effettuato su 18.147 italiani, svolto tra il 27 Marzo 2020 e il 6 Aprile 2020, ha dimostrato la presenza di molti sintomi da stress post-traumatico (37,14% del totale), ansia (20,8% del totale), depressione (17,3% del totale) e disturbi del sonno (7,3% del totale). [1]

Un altro studio effettuato su 2.291 italiani è stato invece condotto tra il 28 Marzo 2020 e il 2 Aprile 2020 mostrando una relazione tra la diffusione del Covid-19 con disturbi del sonno (57,1% del totale), disagio psicologico (41,8% del totale) e ansia (32,1% del totale). [2]

In situazioni come queste, le emozioni possono travolgere intere società secondo dinamiche e logiche complesse.

Sin dall'inizio dell'emergenza sanitaria, abbiamo assistito a come altamente contagiose sono le emozioni ai tempi del Covid-19.

1.2. INTERAZIONE UOMO-COMPUTER (HCI)

Nelle interazioni con altri esseri umani incontriamo continuamente risposte emotive e una grande parte della nostra comunicazione risulta essere di tipo non-verbale. Ciò che permette agli esseri umani di comunicare efficacemente è proprio l'abilità di riconoscere le emozioni.

Azioni prive di alcun tipo di emozione vengono spesso correlate a quelle compiute dai calcolatori, che si occupano dell'esecuzione di un insieme di istruzioni codificate.

Si potrebbe pensare che le emozioni non abbiano nulla a che fare con l'interazione con una macchina, e che per lavorare in maniera efficiente con un calcolatore gli utenti debbano dimenticare il loro stato emotivo.

Ricerche recenti suggeriscono un punto di vista differente, ipotizzando che risulta impossibile per una persona avere la capacità di pensare, o compiere azioni, senza coinvolgere, perlomeno incoscientemente, il proprio sistema emotivo.

L'interazione uomo-computer (HCI, Human-Computer Interaction) è un campo multidisciplinare che si occupa dello studio dell'interazione tra gli umani e le macchine.

Tecnologie emergenti che permettono di valutare le correlazioni fisiologiche delle emozioni, in combinazione ai continui miglioramenti nella qualità dell'elaborazione dei segnali, permettono oggi ai calcolatori di esprimere giudizi sullo stato emotivo dell'utente.

1.3. AFFECTIVE COMPUTING

Il ruolo dell'Affective Computing è quello di rendere possibile un'interazione naturale ed efficace tra gli umani e le macchine, fornendo a quest'ultime la capacità di riconoscere, modellare e rispondere alle nostre emozioni.

Le macchine non sono in grado di riconoscere le emozioni allo stesso modo di noi esseri umani, ma la comprensione dello stato emotivo viene raggiunta attraverso il riconoscimento delle espressioni facciali, o tramite la misura di parametri fisiologici come la frequenza cardiaca o la conduttanza della pelle.

Si deve però tener conto del fatto che le emozioni potrebbero essere auto-indotte dall’utente, per esempio, semplicemente attraverso il pensiero.

E’ quindi molto importante usare dati emotivi realistici.

Il modo migliore per ottenerli è misurare le emozioni durante la vita quotidiana, attraverso dispositivi indossabili mininvasivi.

1.4. MODELLI DI CLASSIFICAZIONE DELLE EMOZIONI

In letteratura, sono stati proposti vari modelli per la classificazione di emozioni, i più rilevanti dei quali possono essere distinti in tre categorie:

- I *modelli categoriali* permettono la classificazione di emozioni in un insieme di classi distinte facilmente descrivibili. Queste classi formano poi le basi per tutte le possibili variazioni emotive.

Questi modelli hanno il pregio di essere semplici, ma non danno la possibilità di riconoscere le emozioni a diverse intensità e non danno la possibilità di combinare diverse emozioni.

- I *modelli dimensionali* prevedono invece che le emozioni possano essere disposte su uno spazio definibile da diverse dimensioni. Questi modelli hanno il vantaggio di poter fornire un’identificazione unica e un’ampia gamma di emozioni, essendo in grado di descrivere emozioni più complesse.

Il modello più utilizzato tra quelli dimensionali è il *modello circonflesso*, proposto da Russell, che considera le emozioni distribuite in uno spazio cartesiano a due dimensioni: arousal e valence. In particolare, la valenza è rappresentata sull’asse delle ascisse, e i suoi valori vanno da *spiacevole* (valenza negativa) a *piacevole* (valenza positiva). L’arousal è rappresentata sull’asse delle ordinate, e i suoi valori vanno da *bassa attivazione* a *elevata attivazione*. L’origine rappresenta un punto di valence neutra e livello medio di arousal.

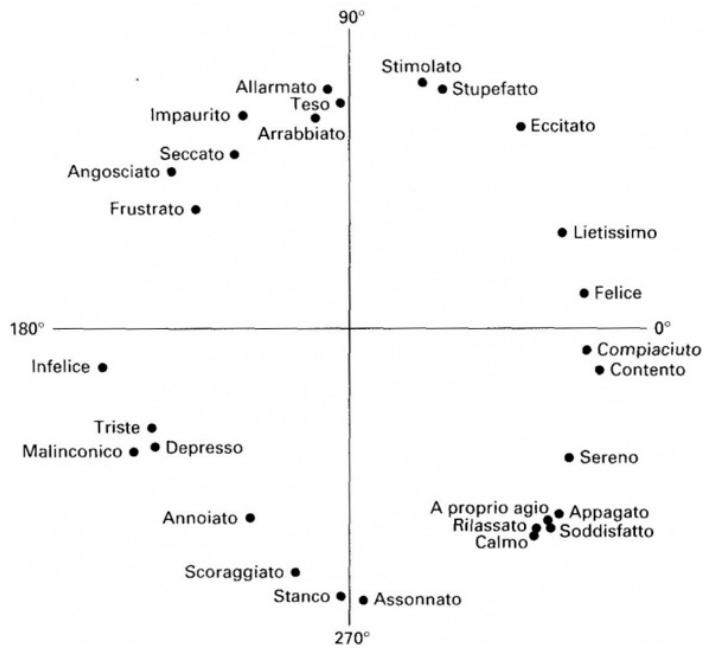


Figura 1. Modello circonflessone di Russel.¹

Questo modello ha la caratteristica di separare emozioni opposte e permette di selezionare emozioni discrete nello spazio, anche se nessuna etichetta viene utilizzata per indicare un sentimento specifico.

- I *modelli componenziali* prevedono che emozioni più complesse siano ottenute come la combinazione di emozioni basilari. Uno degli esempi di questi modelli fu fornito da Robert Plutchik, il quale prevede la presenza di otto emozioni di base: accettazione, anticipazione, rabbia, paura, disgusto, gioia, tristezza e sorpresa. Il resto delle emozioni si ottiene combinando le emozioni di base. Per esempio, la delusione può essere ottenuta dalla combinazione di tristezza e sorpresa.

¹ <https://www.cam.tv/stefystefy1/blog/il-cane-e-le-emozioni/PID048ED5>

1.5. DAI SEGNALI FISIOLOGICI AGLI STATI EMOTIVI

I segnali fisiologici contengono informazioni sulle nostre emozioni.

I recenti progressi nei dispositivi biomedici consentono di identificare nel dettaglio le variazioni nei diversi segnali fisiologici utilizzando l'elettroencefalografia (EEG), l'elettromiografia (EMG), la risposta galvanica della pelle (GSR) e la fotopletismografia (PPG). Le grandezze misurate sono fattori chiave per il riconoscimento delle emozioni poiché riguardano reazioni spontanee, manifestazioni fisiche involontarie.

1.5.1. FOTOPLETISMOGRAFIA (PPG)

La fotopletismografia è una tecnologia non invasiva che si basa su una sorgente di luce e un foto-rilevatore applicati sulla pelle, la combinazione dei quali permette di misurare le variazioni volumetriche della circolazione sanguigna.

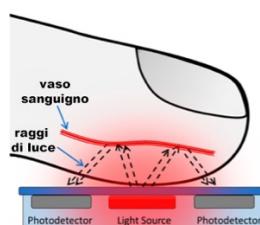


Figura 2. Fotopletismografia.²

Un segnale PPG è caratterizzato da una serie di impulsi che si ripetono periodicamente.

Il singolo impulso è caratterizzato da una prima parte di rapida salita fino al cosiddetto picco sistolico, seguita da una parte di lenta discesa, dove possiamo trovare il cosiddetto picco diastolico.

² adattato da <https://www.mdpi.com/2079-6374/9/3/87/htm>

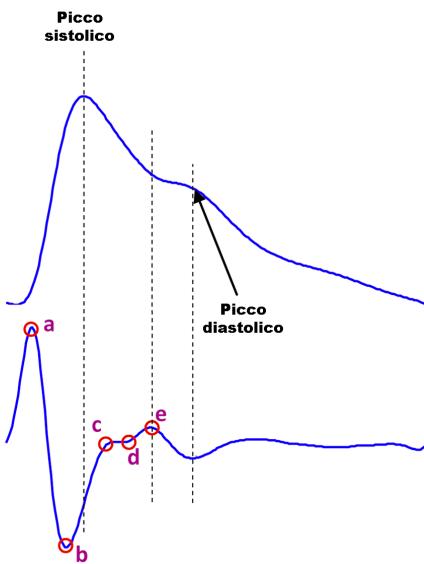


Figura 3. Forma d'onda PPG e la sua derivata seconda.³

La forma d'onda PPG è abbastanza semplice, ma non sempre sufficientemente informativa, tanto che spesso vengono utilizzate le derivate dell'onda, in particolare, la derivata seconda.

Oltre al riconoscimento dello stato emotivo, le forme e i valori del segnale PPG vengono comunemente utilizzati anche per il riconoscimento di problemi di salute. Molti studi hanno dimostrato la sua efficacia nel misurare e valutare la frequenza cardiaca, la saturazione di ossigeno nel sangue e la pressione sanguigna.

I segnali PPG hanno la caratteristica di poter essere facilmente acquisiti, indossando dispositivi wearable di piccole dimensioni.

Le più significative componenti del segnale PPG nel dominio della frequenza si trovano attorno a 1Hz.

³ adattato da https://www.researchgate.net/figure/Typical-PPG-signal-and-its-Second-derivative-wave_fig2_330095092

1.5.2. ELETTROENCEFALOGRAFIA (EEG)

L'elettroencefalografia (EEG) è la registrazione dell'attività elettrica del cervello attraverso l'utilizzo di opportuni elettrodi posizionati sul cuoio capelluto ed è uno strumento molto affidabile per il riconoscimento delle emozioni.

Il cervello produce onde cerebrali contenenti diverse caratteristiche emotive durante la trasmissione di messaggi biologici.

Le onde cerebrali generate da una persona variano a seconda della sua attività. Ad esempio, le onde cerebrali di una persona rilassata sono molto diverse da quelle di una persona che sta svolgendo diverse attività contemporaneamente.

Sulla base di particolari intervalli di frequenza significativi, è possibile identificare cinque tipi di onde, a cui sono associati diversi stati mentali.

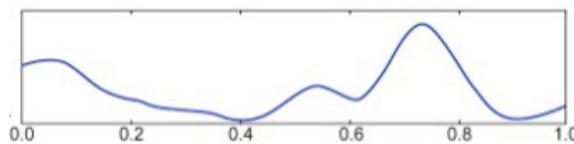


Grafico 1. Onde Delta EEG.⁴

Le onde *Delta* (δ) possono trovarsi nel range di frequenze tra 0.5 e 3 Hz. Sono le onde con i più alti valori di ampiezza e sono le onde cerebrali più lente. Queste vengono tipicamente associate al sonno profondo.

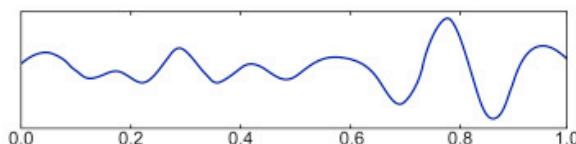


Grafico 2. Onde Theta EEG.⁴

Le onde *Theta* (θ) possono trovarsi nel range di frequenze tra 3.5 e 7.5 Hz. Sono tipicamente presenti durante pensieri creativi, in presenza di sonni coscienti e davanti all'alleviamento di stress.

⁴ adattato da <https://www.sciencedirect.com/topics/agricultural-and-biological-sciences/brain-waves>

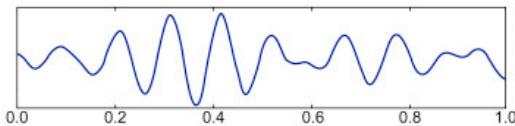


Grafico 3. Onde Alpha EEG.⁴

Le onde *Alpha* (α) possono trovarsi nel range di frequenze tra 7.5 e 13 Hz. Sono tipicamente presenti a fronte di situazioni di calma e relax.

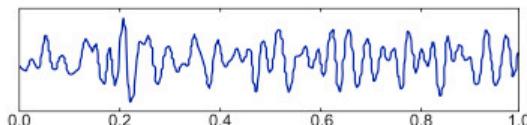


Grafico 4. Onde Beta EEG.⁴

Le onde *Beta* (β) possono trovarsi nel range di frequenze tra 13 e 27 Hz. Si tratta di un'attività veloce ed è il ritmo dominante nelle persone vigili (o ansiose). Sono tipicamente associate a situazioni di alta allerta o concentrazione.

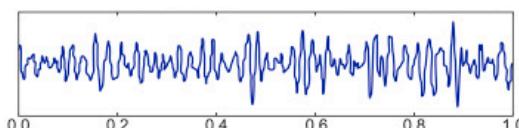


Grafico 5. Onde Gamma EEG.⁴

Le onde *Gamma* (γ) si trovano tipicamente a valori di frequenze maggiori di 27 Hz. Sono tipicamente associate all'esecuzione di diverse attività in contemporanea (multitasking). Sono, inoltre, tipicamente difficili da notare a causa della loro bassa ampiezza.

Alcuni studi hanno dimostrato che le onde ad alta frequenza come alfa, beta e gamma sono più efficaci per classificare le emozioni.

Il calcolo della differenza di potenziale tra gli elettrodi è il principio di base dell'EEG.

Il loro posizionamento è molto importante poiché, se mal posti, i segnali possono essere influenzati dall'attività elettrica del cuore o dei muscoli.

Le frequenze indesiderate vengono tipicamente rimosse utilizzando filtri passabasso, filtri passa-alto e filtri passa-banda rimuovendo quindi segnali come l'elettromiografia (EMG) e l'elettrocardiografia (ECG).

Uno o più elettrodi, detti elettrodi di riferimento, permettono di trovare il campo elettrico di fondo del cranio.

1.5.3. RISPOSTA GALVANICA DELLA PELLE (GSR)

La risposta galvanica della pelle è una risposta elettrodermica che misura il cambiamento delle proprietà di conducibilità della pelle in seguito alla variazione delle condizioni psicofisiologiche.

Lo stato psicologico di una persona tende infatti a rendere attive le ghiandole sudoripare. La salinità del sudore modifica la resistenza della pelle, che assume tipicamente valori compresi tra $5\text{k}\Omega$ e $25\text{k}\Omega$. Ne segue che al cambiamento dello stato emotivo di una persona si verifica una variazione nella risposta galvanica della pelle.

Diversi studi hanno evidenziato la relazione tra il segnale GSR e molteplici stati mentali.

Per esempio, lo stress psicologico tende a rendere le ghiandole sudoripare più attive, la pelle risulterà quindi essere più umida e si avrà quindi un valore di resistenza più basso.

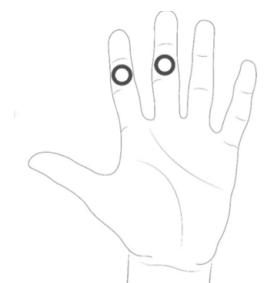


Figura 4. Risposta galvanica della pelle.⁵

Un forte vantaggio del segnale GSR è la sua facilità di registrazione, necessitando solo due elettrodi posti al secondo e terzo dito di una mano.

⁵ adattato da <https://www.brainlatam.com/blog/galvanic-skin-response-module-gsr-module-eeg-bci-2089>

1.5.1. ELETTROMIOGRAFIA (EMG)

L'elettromiografia è una tecnica che permette di valutare l'attività elettrica prodotta dai muscoli scheletrici.

I motoneuroni trasmettono segnali elettrici che provocano la contrazione dei muscoli e l'EMG utilizza degli elettrodi per tradurre questi segnali in opportune grandezze che possono, in seguito, essere opportunamente interpretate.

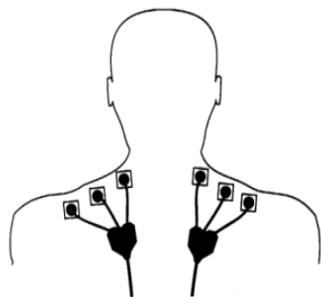


Figura 5. Elettromiografia.⁶

L'elettromiografia è un ottimo strumento per la rilevazione delle emozioni poiché misurabile anche quando non sono presenti delle contrazioni visibili, come quando cerchiamo di controllare il corpo affinché non si manifestino certi comportamenti. Il segnale EMG permette di riconoscere principalmente le emozioni con alti livelli di valence e di arousal, come le emozioni negative.

La frequenza dei segnali EMG è tipicamente compresa nel range dai 10 Hz ai 400-450 Hz.

⁶ adattato da <https://www.bfe.org/protocol/pro08eng.htm>

2. TECNICHE DI MACHINE LEARNING PER LA CLASSIFICAZIONE DI DATI

La classificazione di dati psicofisiologici e la loro interpretazione in termini di stati emozionali può avvenire attraverso l'utilizzo di metodi di intelligenza artificiale.

Il workflow seguito per la realizzazione del classificatore di emozioni si è composto di diversi passi: la raccolta dei dati, l'importazione ed elaborazione dei dati e la loro valutazione attraverso opportune tecniche di machine learning.

Il machine learning si concentra sullo sviluppo di sistemi che possono evolversi se esposti a nuovi dati, con la capacità, quindi, di migliorare in modo automatico attraverso l'esperienza.

Le tecniche di machine learning vengono utilizzate con successo per la ricerca di pattern nascosti nei dati.

Ogni istanza in un dataset usato dagli algoritmi di machine learning viene rappresentata usando un insieme di feature, le quali possono essere continue, categoriche o binarie.

Se le istanze vengono fornite con il corrispondente output corretto (label), vengono quindi “etichettate”, si parla di supervised learning, altrimenti si parla di unsupervised learning.

Un'altra categoria di machine learning è il reinforcement learning, nella quale agenti intelligenti imparano a intraprendere azioni in un dato ambiente al fine di massimizzare le loro ricompense.

L'applicazione sviluppata in questa tesi ricade nei problemi di classificazione, branca del supervised learning nella quale la label ammette un insieme di valori discreti.

La scelta dell'algoritmo di apprendimento da utilizzare è molto importante e diversi sono i metodi di classificazione disponibili con i loro vantaggi e svantaggi.

2.1. K-NEAREST NEIGHBORS (KNN)

KNN è un metodo di classificazione non parametrico semplice ma efficace in molti casi.

Dato un record da classificare, vengono individuati i suoi k record “più vicini”, costruendo così il vicinato del record.

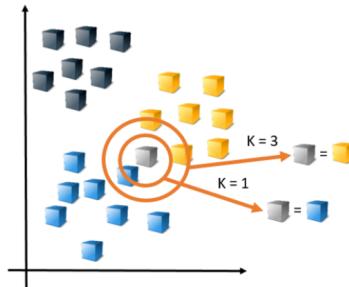


Figura 6. K-Nearest Neighbors.

In funzione della classe maggioritaria a cui appartengono i vicini, viene scelta la label da associare al nostro record.

Il successo della classificazione si basa principalmente sulla giusta scelta del valore di “ k ”. KNN viene tipicamente utilizzato quando si ha una scarsa conoscenza sulla distribuzione dei dati.

2.2. SUPPORT VECTOR MACHINES (SVM)

L’obiettivo dell’algoritmo SVM è quello di trovare un iperpiano in uno spazio di n dimensioni (dove n è il numero di features) in grado di distinguere al meglio un set di dati in diverse classi.

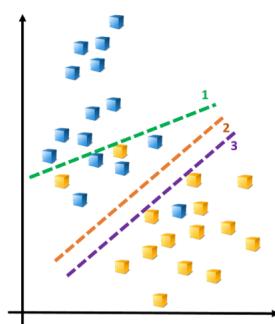


Figura 7. Support Vector Machines.

Individuati i record appartenenti a classi differenti più vicini all'iperpiano, questi vengono definiti vettori di supporto (support vectors) ed influenzano la posizione e l'orientamento dell'iperpiano. Tra tutti gli iperpiani viene scelto quello che meglio divide i vettori di supporto in due classi, cioè quello che ha margine più alto con i vettori di supporto, così da migliorare l'accuratezza del modello.

Se questo iperpiano non esiste, SVM effettua una mappatura non lineare così da portare i dati in una dimensione superiore in modo tale che i dati di due classi possano essere separati da un iperpiano.

2.3. DECISION TREES (DT)

Quello degli alberi di decisione è un metodo di supervised learning non parametrico che ha il compito di creare un modello che predice la classe di un opportuno record, attraverso semplici regole di decisione apprese dalle features dei dati.

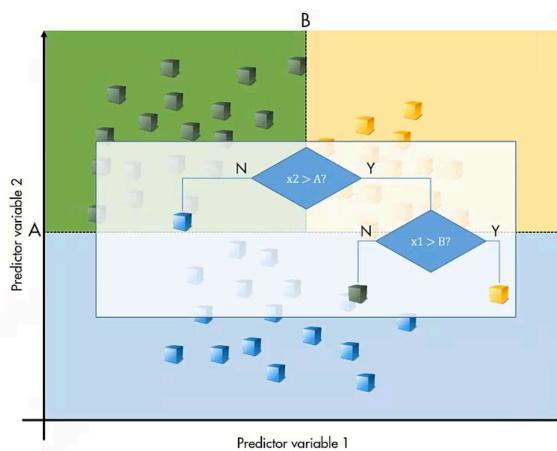


Figura 8. Decision Tree.

Più in particolare, un albero di decisione è un grafo ad albero creato tramite un approccio algoritmico che identifica i modi per suddividere un set di dati in base a diverse condizioni.

Ogni nodo interno rappresenta un test sulle feature, gli archi rappresentano la risposta al test, e ogni foglia rappresenta una label.

Gli alberi di decisione classificano i dati di esempio eseguendo i molteplici test percorrendo l'albero dalla radice al nodo foglia, che fornirà la corretta label.

È spesso utile definire un *criterio di potatura* (pruning), al fine di determinarne la profondità massima del nostro albero. L'aumento della profondità di un albero non è infatti correlato all'accuratezza del modello.

2.4. BAYESIAN NETWORKS (BN)

Una rete bayesiana è un grafo diretto aciclico (DAG) in grado di rappresentare un insieme di variabili casuali e le loro dipendenze condizionali. Ogni nodo rappresenta la variabile casuale che può essere continua o discreta, mentre gli archi rappresentano le condizioni di dipendenza tra le variabili.

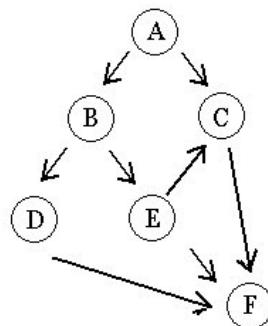


Figura 9. Bayesian Networks.

Le reti bayesiane sono probabilistiche, costruite da una distribuzione di probabilità. La statistica bayesiana dipende dal teorema di Bayes, che ci fornisce la seguente espressione per la probabilità condizionata:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Il teorema ci permette di calcolare la probabilità di un evento A condizionata a un evento B, attraverso la probabilità di B condizionata ad A e le probabilità a priori. Algoritmi efficienti possono trarre diverse capacità di apprendimento dalle reti bayesiane.

2.5. ENSEMBLE LEARNING

Alcuni metodi di machine learning sono considerati *weak learners*, vista la forte dipendenza dai dati utilizzati per il training e quindi due diversi dataset possono produrre predizioni molto differenti.

Un esempio tipico è quello degli alberi di decisione, in cui questo vincolo può essere superato creando un insieme di alberi, una cosiddetta *forest*.

I dati vengono applicati a tutti gli alberi di decisione e i vari risultati vengono poi tra di loro comparati per determinare il risultato finale.

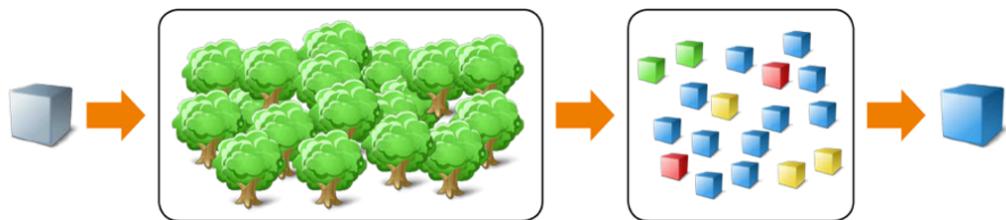


Figura 10. Ensemble Learning.

Le tre classi principali di metodi di ensemble learning sono *bagging*, *stacking* e *boosting*.

Il *bagging* prevede l'utilizzo di molti alberi di decisione su vari campioni dello stesso set di dati e utilizza come risultato finale la media delle previsioni.

Lo *stacking* prevede l'utilizzo di diversi tipi di modelli sugli stessi dati e l'utilizzo di un altro modello per decidere come combinare le previsioni.

Il *boosting* prevede l'aggiunta sequenziale di membri nell'ensemble che correggono le previsioni fatte da precedenti modelli e utilizza come risultato finale una media ponderata delle previsioni.

2.6. ARTIFICIAL NEURAL NETWORKS (ANN)

Una rete neurale è realizzata attraverso la connessione di un insieme di neuroni artificiali.

Ogni neurone prende in ingresso molteplici input e produce in uscita un singolo output, che a sua volta potrà essere usato come l'input di altri neuroni.

Il *percettrone* è un tipo di neurone artificiale che prende in ingresso diversi input binari x_1, x_2, \dots, x_n e produce in uscita un singolo output binario.

Si definiscono inoltre pesi w_1, w_2, \dots, w_n i numeri reali in grado di esprimere l'importanza del corrispondente ingresso.

L'output del percettrone viene calcolato come segue:

$$\text{output} = \begin{cases} 0 & \sum_i w_i x_i \leq \text{valore soglia} \\ 1 & \sum_i w_i x_i > \text{valore soglia} \end{cases}$$

Questa relazione può essere espressa diversamente attraverso il prodotto scalare tra due vettori, e portando il valore soglia dall'altra parte della diseguaglianza, sostituendolo con il cosiddetto bias:

$$\text{output} = \begin{cases} 0 & w * x + b \leq 0 \\ 1 & w * x + b > 0 \end{cases}$$

Modificando il vettore dei pesi e il valore del bias è possibile agire sull'output di un percettrone, con lo scopo di ottenere delle proprietà di apprendimento.

In alcuni casi, piccole modifiche ad un solo percettrone possono essere in grado di cambiare drasticamente il valore dell'uscita.

Questa è una caratteristica dei percettroni, conseguenza dell'avere come funzione di attivazione la funzione a gradino.

$$u(x) = \begin{cases} 1 & x \geq 0 \\ 0 & x < 0 \end{cases}$$

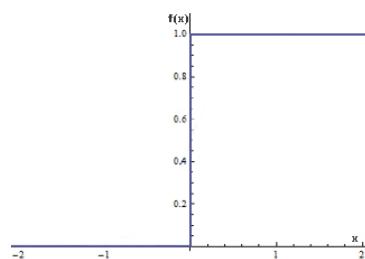


Grafico 6. Funzione a gradino.

Questo problema viene superato con un altro tipo di neurone artificiale, il *neurone sigmoideo*, che presenta una funzione di attivazione molto più fluida della funzione a gradino.

In questo neurone infatti, una piccola modifica comporta solo un piccolo cambiamento nell'uscita.

Gli ingressi possono qui assumere un qualunque valore reale compreso tra 0 e 1 e anche l'uscita assumerà un qualunque valore reale compreso tra questi due estremi. La funzione di attivazione del neurone sigmoideo prende il nome di funzione sigmoidea, funzione matematica in grado di produrre una curva sigmoide introducendo una non linearità nel modello. Questa funzione viene spesso riferita ad un caso speciale di funzione logistica, definita come segue.

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-\sum_i w_i x_i - b}}$$

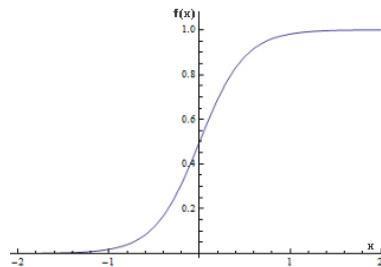


Grafico 7. Funzione sigmoidea.

Una rete composta da molti neuroni artificiali è in grado di prendere decisioni complesse.

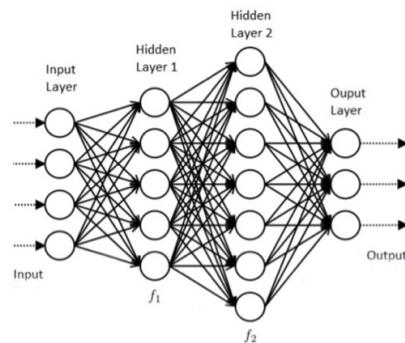


Figura 11. Rete Neurale Artificiale a più livelli.⁷

⁷ <https://www.datasciencecentral.com/profiles/blogs/how-to-configure-the-number-of-layers-and-nodes-in-a-neural>

La prima colonna di neuroni prende il nome di livello di ingresso (input layer), le colonne intermedie prendono il nome di livelli nascosti (hidden layer) e l'ultima colonna prende il nome di livello di output (output layer). Le reti che presentano più livelli nascosti vengono definite reti multistrato (MLP).

Le reti neurali in cui l'output di un livello viene utilizzato come valore di input del successivo livello sono definite reti neurali *feed-forward*.

2.6.1. BACKPROPAGATION

L'algoritmo di Backpropagation viene utilizzato per allenare reti neurali feed-forward.

Nell'adattare una rete neurale l'algoritmo calcola il gradiente di una funzione errore rispetto ai pesi e al bias della rete, così da utilizzare metodi di gradiente per l'addestramento di reti multistrato aggiornando i pesi e il bias in modo da minimizzare la funzione errore.

Tipicamente viene considerata la seguente funzione errore, nota anche come *errore quadratico medio*:

$$C(w, b) = \frac{1}{2N} \sum_x \| y(x) - a \| ^2$$

dove n è il numero di totale di input, a il vettore di output quando x è il corrispondente input e la somma è ottenuta su tutti i valori di input.

Per la minimizzazione della funzione errore tipicamente vengono utilizzati algoritmi come quello di discesa del gradiente o di discesa stocastica del gradiente.

La tecnica di **discesa del gradiente** parte da un punto x_0 e ne calcola il gradiente $\nabla C(x_0)$.

L'opposto di questa quantità fornirà la direzione lungo la quale si ha il massimo decremento.

Ci si muove quindi in quella direzione di una distanza predefinita η , che prende il nome di *learning rate*, trovando un nuovo punto su cui viene calcolato nuovamente il gradiente.

$$v \rightarrow v' = v - \eta \nabla C$$

Seguono successive iterazioni fino all'annullarsi del gradiente.

Utilizzando questa regola di aggiornamento avremo un continuo decremento della funzione errore fino al raggiungimento del minimo globale, sotto opportune condizioni.

In una rete neurale l'algoritmo può essere utilizzato per trovare i valori dei pesi e dei bias tali da ottenere:

$$w_k \rightarrow w'_k = w_k - \eta \frac{\partial C}{\partial w_k}$$

$$b_k \rightarrow b'_k = b_k - \eta \frac{\partial C}{\partial b_k}$$

Una variante, il metodo di discesa del gradiente stocastico, può essere utilizzata per accelerare l'apprendimento.

L'algoritmo di backpropagation viene quindi suddiviso in due fasi:

- l'input viene propagato ai livelli successivi (forward) e si calcola l'errore commesso;
- l'errore viene propagato all'indietro (backward) e i pesi e il bias vengono aggiornati, se necessario;

La rete neurale seguirà nel dettaglio i seguenti passaggi:

- inizializzazione del modello fornendo valori casuali ai pesi;
- calcolo del valore di uscita;
- calcolo della funzione di errore;
- fase effettiva di back-propagation, con aggiornamento dei pesi e bias se necessario;

L'algoritmo di back-propagation può essere interrotto prematuramente quando l'errore diventa sufficientemente piccolo, inferiore ad un valore soglia fissato.

3. RACCOLTA DEI DATI

Per poter addestrare il modello a generare corrette previsioni su nuovi dati, un algoritmo di supervised learning richiede un insieme noto di dati di input con la corretta label associata.

È necessario, quindi, un dataset con una certa quantità di sample descritti in termini di feature. A ciascun sample è associata un'emozione.

I dati utilizzati per il training del modello sono stati ottenuti attraverso il monitoraggio, durante le normali attività quotidiane, delle emozioni di tre soggetti, mediante i sensori descritti di seguito.

3.1. SHIMMER3 GSR+ UNIT

Per l'acquisizione dei dati GSR e dei dati PPG è stato utilizzata l'unità Shimmer3 GSR+.

Questa unità permette l'acquisizione di dati GSR attraverso la misurazione delle caratteristiche elettriche della pelle e di dati PPG attraverso la cattura di un segnale di impulso ottico convertendolo in una stima della frequenza cardiaca.

L'unità GSR+ permette di riconoscere livelli di resistenza della pelle che variano da $8k\Omega$ a $4,7M\Omega$ attraverso l'utilizzo di una rete di resistori interni in grado di fornire un valore di tensione successivamente convertito in un numero a 12 bit, rappresentazione della resistenza della pelle.



Figura 12. Shimmer3 GSR+ Unit.

Per il calcolo della resistenza della pelle a partire dal valore su 12 bit fornito dal convertitore analogico digitale viene utilizzata la seguente formula:

$$Rs = \frac{Rf}{\frac{ADCValue * \frac{3v}{4095}}{0.5v} - 1}$$

dove Rf rappresenta il valore del resistore di retroazione utilizzato dal sensore, $ADCValue$ rappresenta il valore in uscita al convertitore analogico-digitale, $3v/4095$ è la tensione per bit del convertitore analogico-digitale, dove $3v$ è la tensione di riferimento del convertitore e $0.5V$ è la tensione di riferimento utilizzata dal sensore.

La conduttanza della pelle viene successivamente ricavata come reciproco della resistenza:

$$G = \frac{1}{Rs}$$

Nella stessa unità Shimmer3 GSR+ il sensore fotopletismografo è in grado di fornire il segnale PPG da un dito o da un'altra posizione del corpo.

3.2. SHIMMER3 EMG UNIT

Per la registrazione dell'attività elettrica associata alle contrazioni dei muscoli scheletrici è stato utilizzato il sensore Shimmer3 EMG. I segnali vengono raccolti dalla pelle tramite l'utilizzo di cinque cavi, collegati esternamente all'unità, ai quali vengono collegati elettrodi usa e getta convenzionali.



Figura 13. Shimmer3 EMG Unit.

L'unità EMG utilizza un front-end analogico multicanale a bassa potenza costituito da convertitori analogico-digitali delta-sigma e amplificatori a guadagno programmabili.

Di seguito è riportato la panoramica del sistema di base.

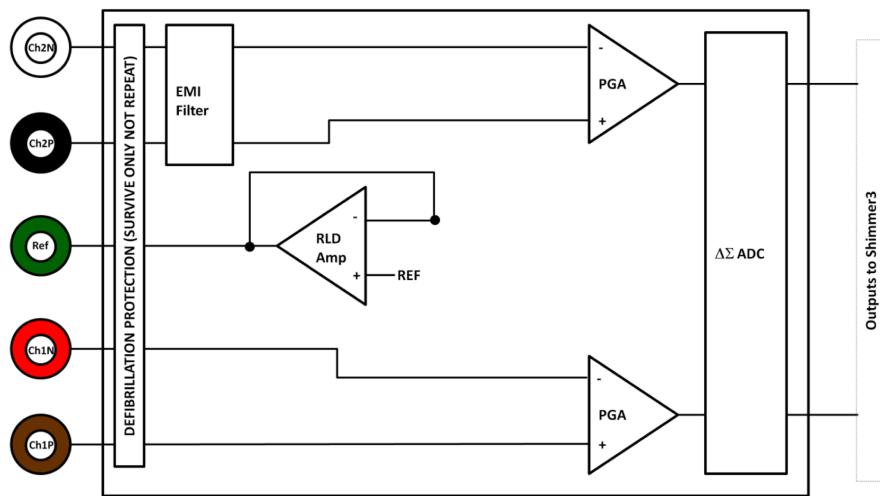


Figura 14. Panoramica del sistema di base dell’unità Shimmer3 EMG. ⁸

È presente un elettrodo positivo e un elettrodo negativo per ciascuno dei due canali e un elettrodo di riferimento neutro.

Troviamo una protezione da defibrillazione, un filtro EMI per la riduzione delle interferenze elettromagnetiche, degli amplificatori a guadagno programmabile e dei convertitori analogico-digitali che si occupano della conversione dei campioni analogici di ingresso in un valore intero con segno a 24 bit. Questi valori vengono inviati al processore Shimmer3 per il salvataggio su scheda SD o trasmissione mediante Bluetooth.

Il segnale raccolto da ogni singolo elettrodo sarà composto da una componente fornita dai muscoli (la componente EMG desiderata), dipendente dalla posizione dell’elettrodo, e da rumore causato dall’ambiente esterno, comune a tutti gli elettrodi ed eliminato attraverso l’amplificatore differenziale.

⁸ <https://bmslab.utwente.nl/wp-content/uploads/2019/12/Shimmer-EMG-muscle-contraction.pdf>

3.3. MUSE S

Per la rilevazione delle attività cerebrali è stato utilizzato Muse S, dispositivo indossabile che sfrutta 4 sensori elettroencefalografici per questa misura.



Figura 15. Muse S.⁹

Le onde cerebrali α , β , δ , γ , θ vengono registrate con una frequenza di 10 Hz per ciascuno dei quattro canali, con valori che variano da $0\mu\text{V}$ a $1862\mu\text{V}$.

I canali del dispositivo per la registrazione del segnale EEG sono i seguenti:

- AF7 - Fronte sinistra;
- AF8 - Fronte destra;
- TP9 - Orecchio sinistro;
- TP10 - Orecchio destro;

3.4. SMART EMOTIONS

Per la collezione dei dati è stata utilizzata l'applicazione Android Smart Emotions sviluppata dall'ingegnere Michele Baldassini.

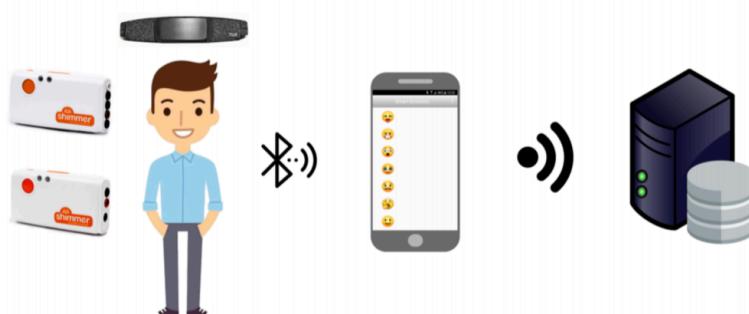


Figura 16. Smart Emotions.

⁹ <https://choosemuse.com/muse-s/>

Durante il monitoraggio delle emozioni, con una cadenza regolare di 10 minuti l'applicazione avvia una sessione di registrazione della durata di circa due minuti, al termine della quale l'utente riceve una notifica per la selezione dell'emozione da associare ai dati appena registrati. L'utente ha la possibilità di esprimere il suo stato emotivo attraverso 7 diverse emozioni (rabbia, ansia, noia, disgusto, paura, felicità e tristezza) con 3 livelli di intensità ciascuna (basso, medio, alto). I dati raccolti vengono caricati su un server in formato csv.

4. ELABORAZIONE DEI DATI

I sensori biometrici precedentemente descritti, coordinati dall'applicazione Smart Emotions, hanno raccolto dati biometrici con una frequenza di 256 Hz sotto forma di file .csv, successivamente elaborati per l'estrazione delle features.

A partire dai campioni registrati da ogni sensore sono stati selezionati i valori in mV per entrambi i canali dell'EMG, il segnale PPG in mV, la resistenza della pelle in kΩ e i Raw Data in μV per ogni canale dell'EEG.

Questi dati sono stati poi opportunamente aggregati per timestamp e associati alla giusta label.

4.1. MATLAB E SIGNAL PROCESSING TOOLBOX

Per l'elaborazione dei dati è stata utilizzata Matlab, piattaforma di programmazione e calcolo numerico per l'implementazione di algoritmi, l'analisi di dati e la creazione di modelli. Un toolbox di Matlab fortemente utilizzato è stato Signal Processing Toolbox, toolbox che fornisce diverse funzioni per l'analisi, l'elaborazione e l'estrazione di feature da segnali.

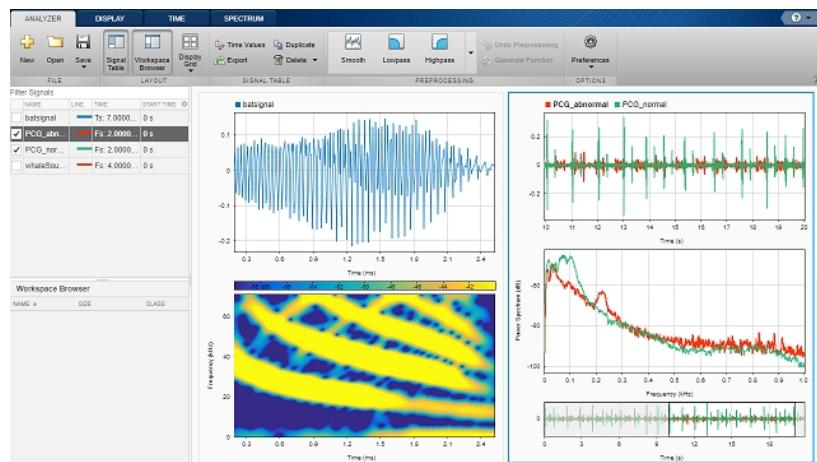


Figura 17. Signal Processing Toolbox Matlab.¹⁰

¹⁰ <https://it.mathworks.com/products/signal.html>

4.2. DATA PREPROCESSING

L'operazione di preprocessing del dataset ha coinvolto dapprima una pulizia dei dati, gestendo i valori mancanti ed eliminando gli outlier dal dataset; i segnali acquisiti dai sensori possono infatti presentare del rumore a causa di movimenti muscolari e/o perdita di contatto con gli elettrodi.

E' stata poi effettuata un'operazione di normalizzazione per distribuire i valori nell'intervallo [0,1], come segue:

$$x = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Sono inoltre state effettuate operazioni di data augmentation e downsampling per bilanciare il dataset, cioè far sì che vi fosse un numero di record simile nelle varie classi.

4.3. ESTRAZIONE DELLE FEATURE

Questo insieme di dati è stato poi suddiviso in sotto-insiemi di 256*W righe, con W variabile, ottenendo così un sotto-insieme di dati che si riferisce a W secondi.

	EMG_CH1_24BIT_CAL_mV	EMG_CH2_24BIT_CAL_mV	PPG_A13_CAL_mV	QSR_Skin_Resistance_CAL_kOhm	RAW_TP9	RAW_AF7	RAW_AF8	RAW_TP10
-9.37778306532973	5.5986517324429829	2785.3479853479853	962.6842105263141	1629.4006	1605.6776	1644.762	1598.4246	
-9.37489802021642	5.58747894614684	2786.080586080586	962.6842105263141	62.454212	74.138919	8.864469	78.55678	
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-9.394731648134984	5.59844143372076	0.7326007326007326	1236.480922316772	1498.0952	1377.619	1496.0806	1342.1611	
-9.417762486257395	5.600754826635698	865.9340609540609	1236.480922316772	108.79121	135.76775	88.64469	143.0403	
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-9.39571731039492	5.613707178478202	802.1978021978022	1237.1601208459215	1164.4689	1238.608	1210.8059	1217.6556	
-9.423195605058408	5.614139082505957	795.4043956043956	1237.8400959521847	68.09524	112.41758	112.82051	104.35897	
-9.48573184192058	5.642507478920275	789.7435897435897	1238.5207588671983	828.022	755.89746	1030.6959	718.022	
-9.443774335702523	5.626905436544272	784.6153846153845	1238.5207588671983	115.64103	71.72161	80.58608	78.166495	

Figura 18. Porzione dell'insieme dei dati non normalizzato prima dell'estrazione delle feature.

Dato un sotto-insieme di dati, per ogni colonna della tabella risultante sono state estratte le seguenti feature:

media	mediana	rapporto magnitudo di picco/RMS
$\frac{\sum_{i=1}^N x_i}{N}$	$x_{(N+1)/2}$ <i>con x vettore ordinato in maniera crescente</i>	$\frac{\ x\ _\infty}{\sqrt{\frac{1}{N} \sum_{i=1}^N x_i ^2}}$
media armonica	trimmed mean	indice di curtosí (kurtosis)
$\frac{N}{\sum_{i=1}^N \frac{1}{x_i}}$	$\frac{\sum_{i=1}^N x_i}{N}$ <i>calcolata dopo aver rimosso gli outliers, ovvero escludendo i k valori più alti e bassi dove</i> $k = N * \frac{\left(\frac{\text{percentuale scelta}}{100}\right)}{2}$	$\gamma_2 = \beta_2 - 3$ $\beta_2 = \frac{m_4^2}{m_2^2}$ <i>dove m_4 e m_2 sono rispettivamente il momento centrale di ordine 4 e di ordine 2</i>
massimo	root-sum-of-squares level	root-mean-square level (RMS)
$\max(x_i)$ $i = 1, \dots, N$	$\sqrt{\sum_{i=1}^N x_i ^2}$	$\sqrt{\frac{1}{N} \sum_{i=1}^N x_i ^2}$
minimo	indice di asimmetria (skewness)	varianza
$\min(x_i)$ $i = 1, \dots, N$	$\gamma_1 = \frac{m_3}{m_2^{3/2}}$ <i>definita tramite i momenti centrali $m_k = E[x'^k]$ ossia i valori attesi della variabile aleatoria centrata</i> $x' = x - E[x]$	$\frac{\sum_{i=1}^N (x_i - x')^2}{N}$ <i>dove $x' = \frac{1}{N} \sum_{i=1}^N x_i$ è la media aritmetica di X.</i>
	deviazione standard	
	$\sqrt{\frac{\sum_{i=1}^N (x_i - x')^2}{N}}$ <i>dove $x' = \frac{1}{N} \sum_{i=1}^N x_i$ è la media aritmetica di X.</i>	

Nel dominio della frequenza sono state invece estratte la media in frequenza, la mediana in frequenza e la banda occupata.

Limitatamente alle onde alpha, beta, gamma, delta e theta, estratte dal segnale EEG attraverso la trasformazione di Fourier e l'utilizzo di filtri passa-banda, sono stati infine calcolati massimo, minimo, media e mediana.

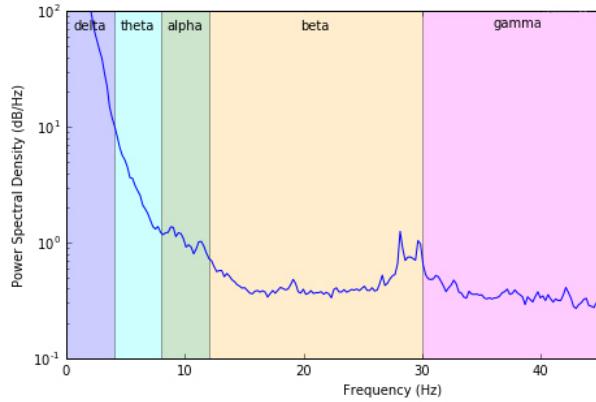


Grafico 8. Spettro del segnale EEG suddiviso in range di frequenze.¹¹

In seguito all'estrazione delle feature, si è ottenuta una tabella risultante dove per ogni riga troviamo le feature di ogni segnale e la corretta label.

La matrice risultante presenta 550 sample, avendo scelto $W = 10$, e 218 colonne con le feature precedentemente elencate.

EEG3-trimmean	EEG3-kurtosis	EEG3-skewness	EEG3-var	EEG3-peak2peak	EEG3-peak2rms	Emotion	Level
806.371989240452	1.66912985075847	0.0098460011911209	36819.7150782978	768.38824	1.43621996152955	disgust	low
806.470271736111	1.62233196144906	0.0096680142607732	60967.8318593666	1025.45792	1.59928848754139	disgust	low
801.972631458333	1.69740354683842	0.0598658681129445	89253.7524173754	1318.7912	1.83649946710516	disgust	low
797.966412847049	2.19967470609536	-0.0141512247768608	92485.0921354012	1648.3883	1.92932967707428	disgust	low
811.343912582465	1.69650575206983	-0.0103401313905002	126913.8880261	1510.989	1.70720141916263	disgust	low
802.645232035359	1.44805736214784	0.0089519888393691	97412.6084991659	946.88647	1.47817587064676	disgust	low
803.826917161458	1.46807982492403	0.00830645523181049	91290.3950213329	965.82417	1.5120464705717	disgust	low
803.866790039062	1.51538333745986	0.015003206535454	93488.679985054	1148.7546	1.6104825573799	disgust	low
802.283923793403	1.58406515395981	0.0193410157785174	86336.578505161	1510.586085	1.90323683935275	disgust	low
801.930486189236	1.43723833242101	0.00890377909242818	104240.463987615	963.00375	1.49632837344826	anxiety	low
803.070372291667	1.44116596217153	0.00982024114732291	110456.257077318	1083.88287	1.59784576250311	anxiety	low
802.472797018229	1.43908876359248	0.0094768078023409	111557.4243040597	1029.48716	1.5202155133445	anxiety	low
801.934507552084	1.49363038630906	0.00796190950741913	112314.355461307	1006.5202	1.50859772013735	anxiety	low
802.41735742188	1.43984495666137	0.0077092762866576	111011.156710061	1061.72165	1.58256943935493	anxiety	low
802.350553841146	1.43658592874618	0.00843839320075629	109419.827643831	1029.89014	1.54019660829678	anxiety	low
802.046782513021	1.4357468614068	0.00758341666994578	108499.438331414	966.63	1.47854747758012	anxiety	low
802.876427404514	1.43961126292514	0.0099331240895715	109479.825802428	1066.95972	1.58971762346583	anxiety	low
802.648554305566	1.43342994828199	0.00757725363996844	109231.482573565	981.94142	1.4925340089346	anxiety	low
802.215019743924	1.4434358767522	0.011188883176007	78666.7446403901	881.61168	1.48366602864549	happiness	medium
802.354575429688	1.4579999021335	0.0125666029219045	77888.2587805729	1010.1465	1.62041352000507	happiness	medium
802.142250711806	1.5981571698405	0.00771983923866128	84648.1578764972	1129.60074	1.67402470254954	happiness	medium
803.524020273438	1.44458200088209	0.00785397003362942	82953.1080394206	927.9488	1.51595941162309	happiness	medium
802.33079282552	1.45015570971686	0.0107421654597063	79691.3653965329	952.93045	1.49806749273169	happiness	medium
803.227416115452	1.44364787110794	0.00988361545318131	74926.9379463219	852.6007	1.45887248864692	happiness	medium
803.460711145833	1.44850196248552	0.00753537309127991	74861.3598631318	919.0843	1.51365083541656	happiness	medium
802.450936132813	1.45056193366996	0.0104300004570695	73805.3968406092	900.95242	1.49908149799835	happiness	medium
803.151343055556	1.47913609165672	0.00987867641398264	77577.2081779584	1037.1429	1.55322686833787	happiness	medium

Figura 19. Piccola porzione dell'insieme di dati non normalizzato in seguito all'estrazione delle feature.

¹¹ <https://still-breathing.net/tag/eeg/>

```

% Lettura file dei sensori
Muse = readable(strcat("path/SensorsCapture/Person_", num2str(Person(p, :),formatSpec),"/Muse_0055DAB90EEB/", string(Dates(p,:)), ".csv");
ShimmerEMG = readable(strcat("path/SensorsCapture/Person_", num2str(Person(p, :),formatSpec),"/Shimmer_000666809BE7/", string(Dates(p,:));
ShimmerGSR_PPG = readable(strcat("path/SensorsCapture/Person_", num2str(Person(p, :),formatSpec),"/Shimmer_000666808EDD/", string(Dates...
% Determino il minor numero di righe tra i tre file per tener conto di eventuali errori di sincronizzazione
[museRows,~] = size(Muse);
[emgRows,~] = size(ShimmerEMG);
[gсррgRows,~] = size(ShimmerGSR_PPG);
minRows = min([museRows,emgRows,gсррgRows]);
windowsNumber = fix(minRows/(256*windowSize))-1;
for i = 0:windowsNumber
    row = [];
    % Estrazione delle features dai dati EEG
    for j = 22:25
        EEGRAW = table2array(Muse(1+i*windowSize*256:(i+1)*windowSize*256,j));
        % Estrazione onde delta, theta, alpha, beta, gamma
        fftEEGRAW = fft(EEGRAW);
        deltaWave = abs(ifft(bandpass(fftEEGRAW, [1 4], 256)));
        thetaWave = abs(ifft(bandpass(fftEEGRAW, [7.5 13], 256)));
        alphaWave = abs(ifft(bandpass(fftEEGRAW, [7.5 13], 256)));
        betaWave = abs(ifft(bandpass(fftEEGRAW, [13 30], 256)));
        gammaWave = abs(ifft(bandpass(fftEEGRAW, [30 44], 256)));
        % Calcolo features
        EEGFeatures = [median(EEGRAW), max(EEGRAW), min(EEGRAW), harmmean(EEGRAW), trimmean(EEGRAW, 10), kurtosis(EEGRAW), skewness(EEGRAW),...];
        row=[row,EEGFeatures];
    end
    % Estrazione delle features dai dati EMG
    EMG1 = table2array(ShimmerEMG(1+i*256*windowSize:(i+1)*windowSize*256,4));
    EMGFeatures1 = [median(EMG1), max(EMG1), min(EMG1), harmmean(EMG1), trimmean(EMG1, 10), kurtosis(EMG1), skewness(EMG1), mean(EMG1, 'omitnan'),...];
    EMG2 = table2array(ShimmerEMG(1+i*256*windowSize:(i+1)*windowSize*256,5));
    EMGFeatures2 = [median(EMG2), max(EMG2), min(EMG2), harmmean(EMG2), trimmean(EMG2, 10), kurtosis(EMG2), skewness(EMG2), mean(EMG2, 'omitnan'),...];
    row=[row,EMGFeatures1, EMGFeatures2];
    % Estrazione delle features dai dati GSR
    GSR = table2array(ShimmerGSR_PPG(1+i*256*windowSize:(i+1)*windowSize*256,5));
    GSRFeatures = [median(GSR), max(GSR), min(GSR), harmmean(GSR), trimmean(GSR, 10), kurtosis(GSR), skewness(GSR), mean(GSR, 'omitnan'),...];
    row=[row,GSRFeatures];
    % Estrazione delle features dai dati PPG
    PPG = table2array(ShimmerGSR_PPG(1+i*256*windowSize:(i+1)*windowSize*256,3));
    PPGFeatures = [median(PPG), max(PPG), min(PPG), harmmean(PPG), trimmean(PPG, 10), kurtosis(PPG), skewness(PPG), mean(PPG, 'omitnan'),...];
    row=[row,PPGFeatures];
    % Aggiorno matrice aggiungendo la nuova riga
    matrix=[matrix;row];
    Responses = [Responses;Evaluations(p,5:6)];
end
end

```

Figura 20. Frammento di codice per l'estrazione delle feature.

4.4. FEATURE SELECTION

Un data set può contenere delle feature tra di loro fortemente correlate o feature che influenzano poco la decisione. L'operazione di feature selection si occupa di scegliere in modo ottimale un sottoinsieme di feature da includere nel modello.

La *sequential feature selection*, in particolare, è una procedura iterativa che richiede una funzione errore e che si occupa di aggiungere e rimuovere a turno delle feature, calcolando l'effetto risultante sulla qualità del modello.

In particolare, procedendo iterativamente, verrà mantenuta la feature se l'errore si sarà ridotto rispetto a quello calcolato al passo precedente.

In seguito alla fase di feature selection, ripetuta per 30 iterazioni, sono state scelte le feature che complessivamente, tra le diverse iterazioni, sono state selezionate dal processo in numero di occorrenze maggiori di un certo threshold, fissato pari a 4.

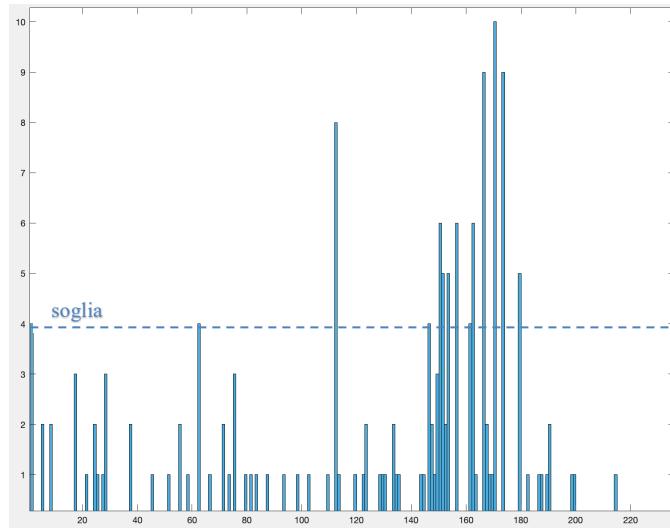


Figura 21. Istogramma del numero di occorrenze delle feature in seguito alla feature selection.

Le feature selezionate sono state: mediana di EEG1, la banda occupata da EEG1, la mediana dell'onda beta di EEG1, la media dell'onda alpha di EEG2, la mediana di EEG3, la mediana di EEG4, il minimo dell'onda theta di EEG4, la mediana di EMG1, il massimo di EMG1, il minimo di EMG1, la trimmed mean di EMG1, la media di EMG1, il root-sum-of-squares level di EMG1, la mediana di EMG2, la trimmed mean di EMG2, la media di EMG2 e il root-sum-of-squares level di EMG2.

```

for n=1:30
    %sequential feature selection
    opts = statset('display', 'iter');
    [fs, history]=sequentialfs(@criterio_pattern, dataAugmented, labelAugmented, 'cv', 4, 'options', opts);
    %scrittura dei risultati su file
    if n==1
        fileID=fopen('../selectedfeatures.txt', 'w');
    else
        fileID=fopen('../selectedfeatures.txt', 'a');
    end
    fprintf(fileID,"%s\n", num2str(find(fs)));
    fclose(fileID);
end
fileID = fopen('../selectedfeatures.txt','r');
formatSpec = '%u';
features = fscanf(fileID,formatSpec);
[GC,GR] = groupcounts(features);
SelectedT = T(:, [ GR(GC >= threshold)', 217, 218 ] );

function y = criterio_pattern(input, target, inputTest, targetTest)
    %vettore di input
    x=input';
    %vettore target
    t=target';
    %scelta della funzione di addestramento
    trainFcN = 'trainscg';
    %numero di neuroni nascosti
    hiddenLayerSize = 5;
    %costruzione della rete
    net = patternnet(hiddenLayerSize,trainFcN);
    %impostazione del metodo di addestramento
    net.divideFcN = 'dividerand';
    net.divideMode = 'sample';
    net.divideParam.trainRatio = 80/100;
    net.divideParam.testRatio = 0/100;
    net.divideParam.valRatio = 20/100;
    %impostazione del metodo di valutazione dell'errore a crossentropy
    net.performFcN = 'crossentropy';
    %scelta delle funzioni di performance da plottare
    net.plotFcns = {'plotperform','plottrainstate', 'plotregression', 'plotconfusion', 'plotfit'};
    %addestramento
    [net, tr]=train(net, x, t); %#ok<ASGLU>
    output=net(inputTest');
    y=perform(net, targetTest', output);
end

```

Figura 22. Frammento di codice per la selezione delle feature.

5. RISULTATI Sperimentali

In questo capitolo si riportano i risultati della classificazione, confrontando i seguenti algoritmi: Decision Trees, Support Vector Machines, K-Nearest Neighbors, Bayesian Networks, Artificial Neural Networks e dei metodi di Ensemble Learning.

5.1. K-FOLD CROSS VALIDATION

Il miglior modo per valutare le performance di un modello è suddividere i dati in un sottoinsieme di dati per il training e un sottoinsieme di dati per il test.

Il modello potrebbe però adattarsi troppo allo specifico modo in cui i dati sono stati suddivisi.

Per ridurre la dipendenza da questa scelta si può usare la K-Fold Cross-Validation, tecnica che prevede che i dati vengano suddivisi casualmente in k sottoinsiemi, detti *fold*, uno dei quali viene utilizzato come set di test e il resto viene utilizzato per il training. Il processo si ripete successivamente con un diverso sottoinsieme utilizzato per il test e così via, fino a utilizzare tutti i sottoinsiemi una volta come set di test. Alla fine del processo viene calcolato l'errore medio e quest'ultimo viene utilizzato come risultato finale.

Il numero di folds utilizzato nella classificazione è stato scelto pari a 5.

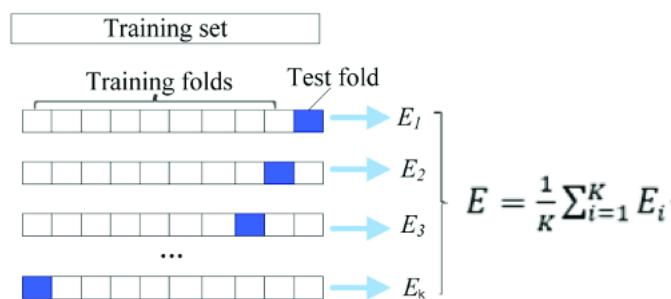


Figura 23. K-Fold Cross Validation.¹²

¹² adattato da https://www.researchgate.net/figure/Ten-fold-cross-validation-diagram-The-dataset-was-divided-into-ten-parts-and-nine-of_fig1_326465007

5.2. VALUTAZIONE MODELLI

Nella valutazione dei modelli, per ogni classificatore la metrica utilizzata è stata l'*accuracy*, parametro che fornisce informazioni su quanto sia stato efficace il modello durante le previsioni.

$$Accuracy = \frac{\text{Emozioni identificate correttamente}}{\text{Numero totale di emozioni}} * 100$$

Il classificatore che ha raggiunto un'accuracy maggiore è stato uno dei metodi di Ensemble Learning, Subspace KNN, e l'accuracy raggiunta è stata 86.0%.

Ad avvicinarsi a questo risultato sono stati KNN (Fine KNN) che ha raggiunto un'accuracy pari all'81.1% e SVM (Fine Gaussian) con un'accuracy dell'80.9%.

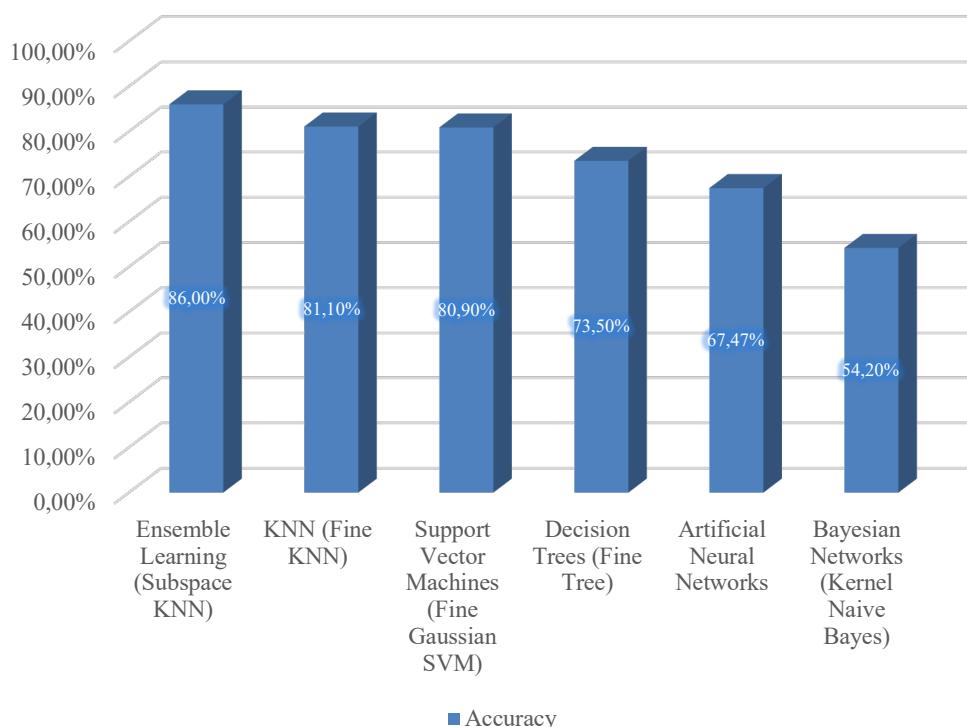
Qui di seguito viene riportata la matrice di confusione del metodo Subspace KNN di Ensemble Learning.

La matrice permette di analizzare gli errori compiuti da un modello di Machine Learning e presenta le previsioni del modello nelle colonne e le classi effettive dei record nelle righe.

	anger	anxiety	boredom	disgust	fear	happiness	sadness
True Class	90						
anger		66			4	2	1
anxiety			67	2	1	12	8
boredom	4	1					
disgust				72			
fear					56		
happiness	4	1	10	3	2	68	5
sadness	5	1	9			2	54
Predicted Class	anger	anxiety	boredom	disgust	fear	happiness	sadness

Figura 24. Matrice di Confusione del metodo Subspace KNN di Ensemble Learning.

Per ordine decrescente di accuracy troviamo poi i seguenti classificatori:



CONCLUSIONI

Lo scopo di questo elaborato è stato quello di cercare di classificare le emozioni a partire da dati ottenuti attraverso una rete di sensori indossabili non invasivi.

Alla luce dei risultati ottenuti è emerso che diverse tecniche di Machine Learning permettono di riconoscere le emozioni in modo sufficientemente accurato.

Il metodo Subspace KNN dell'Ensemble Learning ha tuttavia funzionato meglio rispetto a tutti gli altri algoritmi di classificazione.

Le performance ottenute sono molto promettenti e rendono quindi questo classificatore un primo passo per la realizzazione di uno strumento per applicazioni reali.

Sistemi in grado di riconoscere le emozioni presentano molteplici benefici in ambito sanitario e sociale, come supporto all'individuazione di disturbi cognitivi, di depressione, ansia, ma anche in ambito lavorativo, dove situazioni emotive negative possono ridurre il benessere dei dipendenti.

RINGRAZIAMENTI

Dedico questo spazio a tutti coloro che in me hanno sempre creduto e sostenuto durante il percorso appena giunto al termine.

In primis, ringrazio la mia famiglia per il loro sostegno in questi anni, in particolare mia madre senza la quale oggi tutto questo non sarebbe stato possibile e mia sorella per essermi sempre stata accanto.

Ringrazio i miei nonni, che riescono a starmi vicino anche da lontano.

Un grazie di cuore alla Prof.ssa Ivana Ferraro per il suo enorme supporto ed i suoi indispensabili consigli.

Ringrazio i miei amici, lontani e vicini, che in un modo o nell'altro hanno condiviso con me questi tre anni di gioie e sacrifici.

Grazie in particolare ad Angela, Cristian, Claudio e Giorgia per esserci sempre stati.

Ringrazio i miei compagni di studi Nives, Marco e Davi, con i quali ho iniziato questo percorso, per tutti i bei momenti passati sui banchi di università e Ricky, Martina, Alessandro, i due Dario, Alessandro Gino, Federico e Lorenzo per aver arricchito questa avventura.

Un ringraziamento speciale va inoltre a mio cugino Salvatore e alla sua famiglia per tutto il loro supporto, al mio amico Samuele e alla sua famiglia per l'appoggio dato in questi anni e al mio vicino Massimo per avermi salvato di fronte ai problemi di connessione a Internet.

Ringrazio il Dr. Francesco Pistolesi e l'Ing. Michele Baldassini per le conoscenze trasmesse durante tutto il percorso di stesura dell'elaborato.

Un enorme grazie va anche a questo splendido e duro percorso per avermi aiutato a crescere e a distinguere ciò che conta da ciò che non conta.

Dedico infine questa tesi a me stesso, alla tenacia e ai sacrifici che mi hanno permesso di arrivare a questo risultato.

INDICE DELLE FIGURE

Figura 1. Modello circonflesso di Russel.....	10
Figura 2. Fotopletismografia.....	11
Figura 3. Forma d'onda PPG e la sua derivata seconda.....	12
Figura 4. Risposta galvanica della pelle.....	15
Figura 5. Elettromiografia.....	16
Figura 6. K-Nearest Neighbors.....	18
Figura 7. Support Vector Machines.....	18
Figura 8. Decision Tree.....	19
Figura 9. Bayesian Networks.....	20
Figura 10. Ensemble Learning.....	21
Figura 11. Rete Neurale Artificiale a più livelli.....	23
Figura 12. Shimmer3 GSR+ Unit.....	26
Figura 13. Shimmer3 EMG Unit.....	27
Figura 14. Panoramica del sistema di base dell'unità Shimmer3 EMG.....	28
Figura 15. Muse S.....	29
Figura 16. Smart Emotions.....	29
Figura 17. Signal Processing Toolbox Matlab.....	31
Figura 18. Porzione dell'insieme dei dati non normalizzato prima dell'estrazione delle feature.....	32
Figura 19. Piccola porzione dell'insieme di dati non normalizzato in seguito all'estrazione delle feature.....	34
Figura 20. Frammento di codice per l'estrazione delle feature.....	35
Figura 21. Istogramma del numero di occorrenze delle feature in seguito alla feature selection.....	36
Figura 22. Frammento di codice per la selezione delle feature.....	36
Figura 23. K-Fold Cross Validation.....	37
Figura 24. Matrice di Confusione del metodo Subspace KNN di Ensemble Learning.....	38

INDICE DEI GRAFICI

Grafico 1. Onde Delta EEG.....	13
Grafico 2. Onde Theta EEG.	13
Grafico 3. Onde Alpha EEG.....	14
Grafico 4. Onde Beta EEG.	14
Grafico 5. Onde Gamma EEG.....	14
Grafico 6. Funzione a gradino.....	22
Grafico 7. Funzione sigmoidea.	23
Grafico 8. Spettro del segnale EEG suddiviso in range di frequenze.	34

BIBLIOGRAFIA

- [1] R. e. a. Rossi, «COVID-19 Pandemic and Lockdown Measures Impact on Mental Health Among the General Population in Italy,» 07 Agosto 2020. [Online]. Available: <https://www.frontiersin.org/articles/10.3389/fpsyg.2020.00790/full>.
- [2] M. e. a. Casagrande, «The enemy who sealed the world: effects quarantine due to the COVID-19 on sleep quality, anxiety, and psychological distress in the Italian population,» Novembre 2020. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC7215153/>.
- [3] A. E. M. G. C. S. e. H. N. D. Castaneda, *A review on wearable photoplethysmography sensors and their potential future applications in health care*, nt J Biosens Bioelectron, 2018.
- [4] P. V. e. G. Shivakumar, *Galvanic Skin Response: A Physiological Sensor System for Affective Computing*, International Journal of Machine Learning and Computing vol. 3, no. 1, pp. 31-34., 2013.
- [5] M. Nielsen, *Neural Networks and Deep Learning*, 2020.
- [6] S. Edi, «La dimensione emotivo-affettiva,» 2018. [Online]. Available: <https://www.neuropsicomotricista.it/argomenti/689-tesi-di-laurea/dall-idiozia-mongoloide-alla-trisomia-21-riflessioni-sull-area-emotivo-affettiva/3767-la-dimensione-emotivo-affettiva.html> .
- [7] Wikipedia, «Emotion Classification,» [Online]. Available: https://en.wikipedia.org/wiki/Emotion_classification.

- [8] Shimmer, «GSR+ User Guide Revision 1.13,» [Online]. Available: <https://bmslab.utwente.nl/wp-content/uploads/2019/12/Shimmer-GSR-Skin-conductive-measurements.pdf>.
- [9] Shimmer, «EMG User Guide Revision 1.12,» [Online]. Available: <https://bmslab.utwente.nl/wp-content/uploads/2019/12/Shimmer-EMG-muscle-contraction.pdf>.
- [10] NetAi, «L'algoritmo di backpropagation in una rete neurale,» [Online]. Available: <https://netai.it/lalgoritmo-di-backpropagation-in-una-rete-neurale/#page-content>.
- [11] MathWorks, «Machine Learning with Matlab,» [Online]. Available: <https://it.mathworks.com/learn/online-courses/machine-learning-with-matlab.html>.
- [12] MathWorks, «Signal Processing Toolbox,» [Online]. Available: <https://it.mathworks.com/products/signal.html>.
- [13] «Muse S,» [Online]. Available: <https://choosemuse.com/muse-s/>.
- [14] M. H. S. M. N. H. e. Z. I. R. W. Woaswi, *Human Emotion Detection via Brain Waves Study by Using Electroencephalogram (EEG)*, International Journal on Advanced Science Engineering and Information Technology vol. 6, no. 6, 2016.
- [15] D. Giraldi, Classificazione dei livelli di attivazione e valenza emotiva mediante sensori biometrici, 2016.
- [16] L. Govoni, «Algoritmo Support Vector Machine,» [Online]. Available: <https://www.lorenzogovoni.com/support-vector-machine/>.
- [17] N. S. S. J. M. Jason Teo, EEG-Based Emotion Recognition: A State-of-the-Art Review of Current Trends and Opportunities.

- [18] «The McGill Physiology Virtual Lab,» [Online]. Available: https://www.medicine.mcgill.ca/physio/vlab/biomed_signals/eeg_n.htm.
- [19] W. H. J. Y. K. Hanmoi Sim, A Study on Emotion Classification utilizing Bio-Signal (PPG, GSR, RESP).
- [20] A. Bartolucci, Previsione dell'età biologica mediante segnali PPG.
- [21] J. S. Andrés, Machine Learning and Deep Learning for Emotion Recognition.
- [22] «Bayesian Belief Network in artificial intelligence,» [Online]. Available: <https://www.javatpoint.com/bayesian-belief-network-in-artificial-intelligence>.
- [23] «Emozioni e decisione,» [Online]. Available: psicologia.unicampania.it.